



Exposé

IU Internationale Hochschule

Studiengang: B.Sc. Informatik

# **Einfluss von Chunking-Strategien auf die Retrieval- und Antwortqualität eines Retrieval-Augmented-Generation-Systems für technische Projektdokumentation**

Jonas Weirauch

Matrikelnummer: 10237021

Im Wiesengrund 19, 55286 Sulzheim

Betreuer/in: Prof. Klaus Quibeldey-Cirkel

Abgabedatum: 31.12.2026

# Inhaltsverzeichnis

|                                                             |     |
|-------------------------------------------------------------|-----|
| <b>Abkürzungsverzeichnis</b> . . . . .                      | III |
| <b>1 Einleitung</b> . . . . .                               | 1   |
| <b>2 Theoretische Fundierung</b> . . . . .                  | 2   |
| 2.1 Grundlagen von Retrieval-Augmented Generation . . . . . | 2   |
| 2.2 Chunking und Evaluation von RAG-Systemen . . . . .      | 2   |
| <b>3 Methodik / Forschungsdesign</b> . . . . .              | 4   |
| <b>4 Geplante Gliederung</b> . . . . .                      | 5   |
| <b>5 Zeitplan</b> . . . . .                                 | 5   |
| <b>Literaturverzeichnis</b> . . . . .                       | 6   |

## Abkürzungsverzeichnis

|              |                                           |
|--------------|-------------------------------------------|
| <b>API</b>   | Application Programming Interface         |
| <b>DPR</b>   | Dense Passage Retrieval                   |
| <b>LLM</b>   | Large Language Model                      |
| <b>MRR</b>   | Mean Reciprocal Rank                      |
| <b>NLG</b>   | Natural Language Generation               |
| <b>RAG</b>   | Retrieval-Augmented Generation            |
| <b>RAGAS</b> | Retrieval-Augmented Generation Assessment |

# 1 Einleitung

Technische Dokumentationen von Softwareprojekten bündeln umfangreiches projektspezifisches Wissen, das für Entwicklung, Wartung und Einarbeitung von zentraler Bedeutung ist. Dieses Wissen ist häufig über zahlreiche Dateien und Abstraktionsebenen verteilt, sodass die gezielte Beantwortung konkreter Fragen einen erheblichen manuellen Suchaufwand erfordert. Große Sprachmodelle (Large Language Models, LLM) können natürlichsprachliche Fragen beantworten, verfügen jedoch ohne zusätzlichen Kontext nicht zuverlässig über aktuelles oder projektspezifisches Wissen und neigen zur Generierung inhaltlich nicht gedeckter Aussagen (Ji et al., 2023).

Retrieval-Augmented Generation (RAG) adressiert diese Einschränkung, indem relevante Dokumentstellen zur Laufzeit abgerufen und dem Sprachmodell als Kontext bereitgestellt werden (Lewis et al., 2020). Die Qualität eines solchen Systems hängt maßgeblich davon ab, wie die zugrunde liegenden Dokumente aufbereitet und in abrufbare Textsegmente zerlegt werden (Gao et al., 2023). Dieser als Chunking bezeichnete Verarbeitungsschritt bestimmt, welche Informationen überhaupt indexiert und im Retrieval gefunden werden können.

Die Problemstellung ergibt sich aus den gegenläufigen Anforderungen an die Segmentierung: Zu kleine Segmente können den notwendigen Kontext verlieren, zu große Segmente erhöhen den Anteil irrelevanter Information, und eine an der Dokumentstruktur unausgerichtete Zerlegung kann semantisch zusammengehörige Inhalte trennen (Jimeno Yepes et al., 2024). Trotz der praktischen Relevanz dieser Entscheidung liegt für technische Projektdokumentation bislang wenig systematische Evidenz dazu vor, wie sich einzelne Chunking-Strategien auf die Retrieval- und Antwortqualität auswirken.

Die wissenschaftliche Relevanz liegt in der Notwendigkeit, RAG-Systeme komponentenweise zu bewerten (Yu et al., 2025). Die praktische Relevanz besteht in der zunehmenden Verbreitung dokumentenbasierter Assistenzsysteme, deren Wirksamkeit unmittelbar von der Wahl der Chunking-Strategie abhängt. Kontrollierte Vergleiche liegen bislang überwiegend für spezialisierte Fachdomänen vor, etwa für unternehmensinterne technische Dokumente (Taiwo & Yusoff, 2026) oder die klinische Entscheidungsunterstützung (Gomez-Cabello et al., 2025), während für entwicklerorientierte Open-Source-Softwaredokumentation systematische Evidenz fehlt. Aus dieser Ausgangslage leitet sich die folgende Forschungsfrage ab:

*Wie beeinflussen unterschiedliche Chunking-Strategien die Retrieval- und Antwortqualität eines Retrieval-Augmented-Generation-Systems bei der Beantwortung projektspezifischer Fragen auf Basis technischer Open-Source-Dokumentation?*

Ziel der Arbeit ist die Konzeption, Implementierung und Evaluation einer RAG-Pipeline zur fragebasierten Erschließung technischer Open-Source-Dokumentation am Beispiel der Vue.js-Dokumentation. Im Mittelpunkt steht der kontrollierte Vergleich mehrerer Chunking-Strategien, wobei sämtliche übrigen Komponenten der Pipeline konstant gehalten werden, um den Einfluss der Segmentierung isoliert messbar zu machen. Auf Basis der Ergebnisse werden begründete Handlungsempfehlungen für die Gestaltung dokumentenbasierter RAG-Systeme abgeleitet.

Der Aufbau der Arbeit folgt dieser Zielsetzung: Nach der Einleitung werden die theoretischen Grundlagen dargestellt, gefolgt vom Forschungsdesign und dem Evaluationsverfahren. Es folgen die Ergebnisse sowie deren Diskussion. Die Arbeit schließt mit Fazit und Limitationen.

## 2 Theoretische Fundierung

### 2.1 Grundlagen von Retrieval-Augmented Generation

Große Sprachmodelle sind auf umfangreichen Textkorpora vortrainierte neuronale Modelle, die auf Basis von Wahrscheinlichkeitsverteilungen natürlichsprachliche Texte verarbeiten und erzeugen. Mit der Einführung kontextsensitiver Repräsentationen durch transformerbasierte Architekturen wurde die semantische Verarbeitung von Sprache deutlich verbessert (Devlin et al., 2019). Für die Suche in Dokumentbeständen ist insbesondere die Abbildung von Texten auf numerische Vektoren, sogenannte Embeddings, relevant. Embeddings repräsentieren Bedeutung in einem hochdimensionalen Vektorraum, in dem semantisch ähnliche Texte räumlich benachbart liegen, sodass Ähnlichkeit über Distanz- oder Winkelmaße bestimmbar wird (Reimers & Gurevych, 2019). Diese Eigenschaft bildet die technische Grundlage der vektorbasierten Suche, bei der eine Anfrage und Dokumentsegmente im selben Vektorraum verglichen werden. Die Qualität der erzeugten Vektoren hängt dabei vom eingesetzten Embedding-Modell ab; satzbasierte Modelle, die speziell für die Abbildung semantischer Ähnlichkeit trainiert wurden, haben sich für Retrieval-Aufgaben als besonders geeignet erwiesen.

Retrieval-Augmented Generation verbindet ein generatives Sprachmodell mit einer externen Wissensquelle. Zur Laufzeit werden für eine Anfrage relevante Dokumentstellen abgerufen und gemeinsam mit der Anfrage an das Sprachmodell übergeben, das die Antwort auf Basis dieses Kontextes erzeugt (Lewis et al., 2020). Ein RAG-System lässt sich in die Teilschritte Dokumentvorverarbeitung, Segmentierung, Einbettung, Indexierung, Abruf, Kontextzusammenstellung und Antwortgenerierung gliedern (Gao et al., 2023). Jeder dieser Teilschritte stellt einen potenziellen Einflussfaktor auf die Gesamtqualität dar, weshalb eine isolierte Untersuchung einzelner Komponenten für ein differenziertes Verständnis notwendig ist. Der Abruf erfolgt häufig über dichte Vektorrepräsentationen (Dense Retrieval), bei denen Anfragen und Passagen durch gelernte Embeddings verglichen werden; dieses Verfahren hat sich gegenüber rein lexikalischer Suche bei der Beantwortung offener Fragen als leistungsfähig erwiesen (Karpukhin et al., 2020). Der Ansatz adressiert insbesondere die Probleme fehlender Aktualität, mangelnder Domänenspezifik und nicht belegter Aussagen, die bei der alleinigen Nutzung des Modellwissens auftreten. Eine Halluzination liegt dabei vor, wenn die generierte Antwort Informationen enthält, die weder durch die bereitgestellten Kontextpassagen noch durch die Referenzantwort gedeckt sind oder diesen widersprechen (Ji et al., 2023). Für die geplante Arbeit wird Dense Retrieval als Abrufverfahren gewählt, da es sich für die vektorbasierte Suche in strukturierten Dokumentbeständen bewährt hat und eine konsistente Vergleichsbasis über alle Chunking-Strategien hinweg gewährleistet. Dabei werden die abgerufenen Textsegmente gemeinsam mit der ursprünglichen Anfrage in einem strukturierten Prompt zusammengeführt, sodass das Sprachmodell die Antwort ausschließlich auf Basis des bereitgestellten Kontextes erzeugt. Durch die Konstanzhaltung des Prompts, des Sprachmodells und der Abrufparameter über alle Versuchsbedingungen hinweg wird sichergestellt, dass beobachtete Unterschiede in der Antwortqualität auf die Segmentierung und nicht auf andere Pipeline-Komponenten zurückzuführen sind.

## 2.2 Chunking und Evaluation von RAG-Systemen

Chunking bezeichnet die Zerlegung von Dokumenten in abrufbare Textsegmente. Die Segmentierung bestimmt die Granularität der indexierten Einheiten und beeinflusst damit unmittelbar, welche Informationen im Retrieval auffindbar sind. In der Literatur werden im Wesentlichen größenbasierte und strukturbasierte Verfahren unterschieden. Größenbasierte Strategien zerlegen Texte in Segmente fester Länge, optional mit Überlappung benachbarter Segmente, um den Verlust von Information an Segmentgrenzen zu verringern. Strukturbasierte Strategien orientieren sich an der Dokumentstruktur, etwa an Überschriftenebenen, und erhalten dadurch semantisch zusammenhängende Einheiten (Jimeno Yepes et al., 2024). Empirische Untersuchungen zeigen, dass die Wahl der Segmentgröße einen messbaren Einfluss auf die Leistungsfähigkeit von RAG-Systemen hat (Hladěna et al., 2025), und dass Retriever, Segmentierung und Generierung als zusammenhängende Einflussgrößen zu betrachten sind (Finardi et al., 2024). Der Vorteil aufwändigerer Segmentierung ist allerdings nicht gesichert: Vergleichende Untersuchungen zeigen, dass semantisch oder strukturell motivierte Verfahren größenbasiertes Chunking nicht konsistent übertreffen und der zusätzliche Aufwand häufig nicht durch entsprechende Qualitätsgewinne gerechtfertigt wird (Qu et al., 2025). Größenbasiertes Chunking mit Überlappung stellt somit keine triviale Ausgangsbasis, sondern einen leistungsfähigen Vergleichsmaßstab dar. Der eigentliche Erkenntnisgewinn eines kontrollierten Vergleichs liegt daher nicht in der Frage, welche Strategie pauschal überlegen ist, sondern in der differenzierten Betrachtung von Effektgröße, Kosten, Metrik-Abhängigkeit und der Interaktion mit unterschiedlichen Fragetypen. Für technische Projektdokumentation, die typischerweise klar strukturierte und überschchriftenbasierte Inhalte aufweist, ist die vergleichende Untersuchung dieser Strategien von besonderer Bedeutung.

Die Bewertung von RAG-Systemen erfolgt auf zwei Ebenen. Auf der Retrieval-Ebene wird geprüft, ob die für eine Anfrage relevanten Dokumentstellen abgerufen werden; hierfür werden etablierte Maße der Informationsbeschaffung verwendet, insbesondere Precision und Recall sowie der Mean Reciprocal Rank, der die Position des ersten relevanten Treffers bewertet (Manning et al., 2008). Auf der Antwortebene wird die generierte Antwort hinsichtlich Korrektheit, Vollständigkeit, Quellenbezug und Halluzinationsfreiheit beurteilt. Aktuelle Übersichtsarbeiten betonen, dass eine aussagekräftige Bewertung beide Ebenen sowie die Qualität des bereitgestellten Kontextes berücksichtigen muss (Yu et al., 2025). Ergänzend wurden automatisierte Evaluationsverfahren vorgeschlagen, die Aspekte wie Faithfulness und Kontextrelevanz mithilfe von Sprachmodellen schätzen (Es et al., 2024); solche Verfahren gelten als hilfreiche Ergänzung, ersetzen eine referenzbasierte Bewertung mit definierter Ground Truth jedoch nicht vollständig, da modellgestützte Bewertungen methodisch angreifbar bleiben (Yu et al., 2025). Der dargestellte Forschungsstand zeigt, dass Chunking als eigenständiger Einflussfaktor anerkannt ist. Kontrolliert erhobene Vergleiche einzelner Strategien liegen jedoch überwiegend für spezialisierte Fachdomänen vor, etwa für unternehmensinterne technische Dokumente (Taiwo & Yusoff, 2026) oder die klinische Entscheidungsunterstützung (Gomez-Cabello et al., 2025). Die Dokumentmerkmale dieser Domänen unterscheiden sich von entwicklerorientierter Open-Source-Softwaredokumentation, die typischerweise strukturierte Markdown-Inhalte, eine Mischung aus konzeptuellen und prozeduralen Abschnitten sowie eingebettete Codebeispiele aufweist. Für diesen Dokumenttyp liegt bislang wenig systematische, vergleichende Evidenz vor. An dieser Forschungslücke setzt die geplante Arbeit an, indem sie mehrere Chunking-Strategien unter konstanten Rahmenbedingungen auf einem ausgezeichnet dokumentierten Softwareprojekt vergleicht und die Antwortqualität primär referenzbasiert bewertet.

### 3 Methodik / Forschungsdesign

Zur Beantwortung der Forschungsfrage wird ein experimenteller Vergleich dreier Chunking-Strategien gewählt, und zwar größenbasiertes Chunking ohne Überlappung, größenbasiertes Chunking mit Überlappung sowie strukturbasiertes Chunking entlang der Markdown-Überschriften. Dabei wird ausschließlich die Segmentierung als unabhängige Variable variiert und alle übrigen Pipeline-Komponenten konstant gehalten, insbesondere der Dokumentkorpus, das Embedding-Modell, das Sprachmodell, die Temperatur, die Anzahl abgerufener Segmente, der verwendete Prompt, der Fragenkatalog, die Bewertungsrubrik sowie der Vektorindex. Durch diese Isolierung lassen sich beobachtete Unterschiede in der Retrieval- und Antwortqualität auf die Chunking-Strategie zurückführen. Ein experimenteller Vergleich ist zur Beantwortung der Forschungsfrage geeignet, weil diese auf einen kausal interpretierbaren Einfluss der Segmentierung abzielt.

Aus dem dargestellten Forschungsstand werden drei explorative Hypothesen abgeleitet, die im Rahmen der Auswertung überprüft werden: (H1) Strukturbasiertes Chunking übertrifft größenbasiertes ohne Überlappung hinsichtlich der Retrieval-Qualität, nicht aber durchgängig größenbasiertes mit Überlappung, da diese den Informationsverlust an Segmentgrenzen weitgehend kompensiert. (H2) Retrieval-Unterschiede übertragen sich nur teilweise auf die Antwortqualität, da das Sprachmodell moderate Defizite ausgleichen kann. (H3) Die relative Eignung der Strategien variiert nach Fragetyp, wobei strukturbasiertes Chunking insbesondere konzeptuelle, abschnittsübergreifende Fragen begünstigt, während größenbasierte Verfahren für eng umgrenzte faktische Fragen ausreichen. Die Hypothesen werden nicht inferenzstatistisch bestätigt, sondern dienen als explorative Leitannahmen für die deskriptive Auswertung.


Als Datengrundlage dient ein fixierter, über einen konkreten Commit reproduzierbarer Snapshot der englischsprachigen Dokumentation des JavaScript-Frameworks Vue.js, die als entwicklerorientiert und didaktisch hochwertig gilt, technisch differenzierte konzeptuelle und prozedurale Inhalte umfasst und durchgängig in Markdown vorliegt. Der Korpus wird bewusst auf ausgewählte Bereiche begrenzt und in einem Korpusmanifest dokumentiert. Die Datenerhebung umfasst einen manuell kuratierten Fragenkatalog von etwa 40 Fragen unterschiedlicher Typen (faktisch, prozedural, konzeptuell, vergleichend, Fehler-/Randfälle) mit vorab festgelegten Referenzantworten und annotierten Quellen als Ground Truth. Die vorherige Festlegung der Referenzdaten dient der Vermeidung einer nachträglichen, ergebnisorientierten Anpassung der Bewertungsgrundlage.

Die Retrieval-Evaluation verwendet Recall@k, Precision@k und Mean Reciprocal Rank (Manning et al., 2008); die Antwortqualität wird anhand einer gleich gewichteten Rubrik (Skala 0 bis 2) mit den Kriterien Korrektheit, Vollständigkeit, Quellenbezug, Halluzinationsfreiheit und Verständlichkeit beurteilt. Zur Triangulation dient die referenzbasierte manuelle Bewertung als primäres Verfahren, da sie auf einer vorab definierten Ground Truth beruht und nicht zirkulär ist. Ergänzend wird ein automatisiertes Evaluationsframework (Es et al., 2024) als sekundäres Verfahren eingesetzt; die Übereinstimmung beider Verfahren wird als zusätzlicher Validitätsindikator herangezogen (Yu et al., 2025). Ergänzend werden Effizienzkennzahlen (Chunk-Anzahl, Indexgröße, Token-Verbrauch) erfasst, um die Qualitätsunterschiede den jeweiligen Kosten der Strategien gegenüberzustellen. Die interne Validität wird durch Konstanthaltung der Parameter und eine Temperatur von null gestützt; die externe Validität ist durch den einzelnen Korpus begrenzt. Diese Limitationen werden in der Arbeit offengelegt und bei der Interpretation der Ergebnisse berücksichtigt.

## 4 Geplante Gliederung

- 1 Einleitung**
  - 1.1 Problemstellung und Ausgangslage
  - 1.2 Zielsetzung und Forschungsfrage
  - 1.3 Aufbau der Arbeit
- 2 Theoretische Fundierung**
  - 2.1 Sprachmodelle und vektorbasierte Textrepräsentation
  - 2.2 Retrieval-Augmented Generation
  - 2.3 Chunking technischer Dokumentation
  - 2.4 Evaluation von RAG-Systemen
  - 2.5 Forschungsstand und Forschungslücke
- 3 Methodik und Forschungsdesign**
  - 3.1 Forschungsdesign
  - 3.2 Dokumentkorpora und Snapshot
  - 3.3 Fragenkatalog und Referenzdaten
  - 3.4 Evaluationsverfahren
  - 3.5 Implementierung
- 4 Präsentation und Analyse der Forschungsergebnisse**
  - 4.1 Ergebnisse der Retrieval-Evaluation
  - 4.2 Ergebnisse der Antwortbewertung
  - 4.3 Zusammenhang von Retrieval- und Antwortqualität
  - 4.4 Effizienzbetrachtung
- 5 Diskussion und Handlungsempfehlungen**
  - 5.1 Interpretation der Ergebnisse
  - 5.2 Handlungsempfehlungen
  - 5.3 Validitätsbetrachtung
- 6 Fazit und Limitationen**
  - 6.1 Beantwortung der Forschungsfrage
  - 6.2 Ausblick auf weiterführende Forschung

## 5 Zeitplan



**Abb. 1:** Geplanter Zeitplan der Bachelorarbeit (Oktober bis Dezember 2026)

Eigene Darstellung.

# Literaturverzeichnis

- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. DOI: 10.18653/v1/N19-1423.
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAs: Automated Evaluation of Retrieval Augmented Generation. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150–158. DOI: 10.18653/v1/2024.eacl-demo.16.
- Finardi, P., Avila, L., Castaldoni, R., Gengo, P., Larcher, C., Piau, M., Costa, P., & Caridá, V. (2024). The Chronicles of RAG: The Retriever, the Chunk and the Generator [arXiv-Preprint arXiv:2401.07883]. DOI: 10.48550/arXiv.2401.07883.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Guo, Q., Wang, M., & Wang, H. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey [arXiv-Preprint arXiv:2312.10997]. DOI: 10.48550/arXiv.2312.10997.
- Gomez-Cabello, C. A., Prabha, S., Haider, S. A., Genovese, A., Collaco, B. G., Wood, N. G., Bagaria, S., & Forte, A. J. (2025). Comparative Evaluation of Advanced Chunking for Retrieval-Augmented Generation in Large Language Models for Clinical Decision Support. *Bioengineering*, 12(11), 1194. DOI: 10.3390/bioengineering12111194.
- Hladěna, J., Šteflovíč, K., Čech, P., Štekerová, K., & Žváčková, A. (2025). The Effect of Chunk Size on the RAG Performance. *Software Engineering: Emerging Trends and Practices in System Development (CSOC 2025)*, 1559, 317–326. DOI: 10.1007/978-3-032-00712-4\_21.
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12), 1–38. DOI: 10.1145/3571730.
- Jimeno Yepes, A., You, Y., Milczek, J., Laverde, S., & Li, R. (2024). Financial Report Chunking for Effective Retrieval Augmented Generation [arXiv-Preprint arXiv:2402.05131]. DOI: 10.48550/arXiv.2402.05131.
- Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W.-t. (2020). Dense Passage Retrieval for Open-Domain Question Answering. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 6769–6781. DOI: 10.18653/v1/2020.emnlp-main.550.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for

Knowledge-Intensive NLP Tasks. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan & H. Lin (Hrsg.), *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)* (S. 9459–9474). Curran Associates, Inc.

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.

Qu, R., Bao, F., & Tu, R. (2025). Is Semantic Chunking Worth the Computational Cost? *Findings of the Association for Computational Linguistics: NAACL 2025*. DOI: 10.18653/v1/2025.findings-naacl.114.

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. DOI: 10.18653/v1/D19-1410.

Taiwo, S., & Yusoff, M. A. (2026). Evaluating Chunking Strategies for Retrieval-Augmented Generation in Oil and Gas Enterprise Documents [arXiv-Preprint arXiv:2603.24556].

Yu, H., Gan, A., Zhang, K., Tong, S., Liu, Q., & Liu, Z. (2025). Evaluation of Retrieval-Augmented Generation: A Survey. *Big Data (BigData 2024)*, 2301, 102–120. DOI: 10.1007/978-981-96-1024-2\_8.